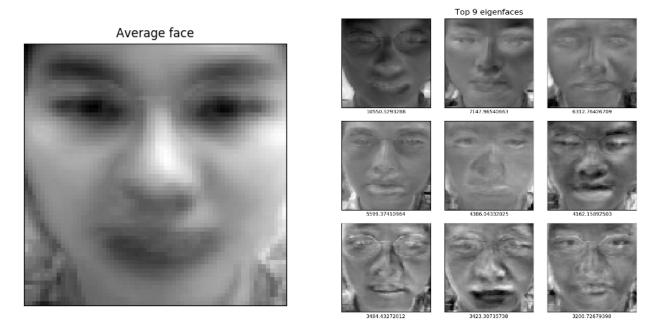
學號:B03901039 系級:電機三 姓名:童寬

1.1. Dataset 中前 10 個人的前 10 張照片的平均臉和 PCA 得到的前 9 個 eigenfaces:

答: (左圖平均臉,右圖為 3x3 格狀 eigenfaces, 順序為左到右再上到下,圖的下標為 eigenvalue)



1.2. Dataset 中前 10 個人的前 10 張照片的原始圖片和 reconstruct 圖 (用前 5 個 eigenfaces): 答:(左右各為 10x10 格狀的圖, 順序一樣是左到右再上到下)



1.3. Dataset 中前 10 個人的前 10 張照片投影到 top k eigenfaces 時就可以達到 < 1% 的 reconstruction error.

答: (回答 k 是多少)

k = 59

rmse = 0.9968%

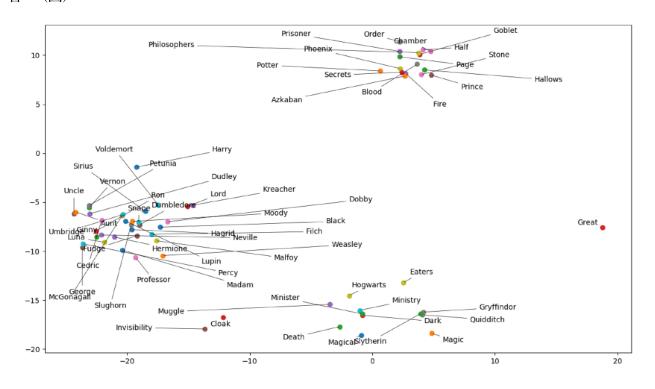
2.1. 使用 word2vec toolkit 的各個參數的值與其意義:

答:

| 參數 | 初始值 | 我使用的數值 | 意義 |
|------------|--------|--------|---|
| size | 100 | 100 | 每個 word vector 的 dimension |
| window | 5 | 5 | 決定多長的前後文算是有關係的 context |
| sample | '1e-3' | '1e-3' | 出現頻率比此值高的字會被 down sample |
| hs | 0 | 0 | 決定是否使用 Hierarchical Softmax 指在算 softmax 前先判斷輸出的字是哪一類的 (要事先做分類),再判斷是那一個字 |
| negative | 5 | 5 | 選擇幾個 negative samples 指的是跟目標字沒有關係的 sample context 它們在目標函數中要被最小化 |
| threads | 12 | 12 | 看要用多少 threads 去計算,可以加速訓練時間 |
| iter_ | 5 | 5 | 看要訓練幾個 iterations |
| min_count | 5 | 5 | 出現次數少於此值的字,不會列入訓練 |
| alpha | 0.025 | 0.025 | 起始學習速率 |
| debug | 2 | 2 | debug 的模式,2 表示有較多的 debug 訊息 |
| binary | 1 | 1 | 決定是否將 word vector 以 binary 方式儲存 |
| cbow | 1 | 1 | 決定是否使用 continuous back of words model 指的是給周圍的字去算目標字的機率 |
| save_vocab | None | None | 決定是否儲存 vocabulary |
| read_vocab | None | None | 決定是否讀取 vocabulary |
| verbose | FALSE | TRUE | 決定是否印出 output |

2.2. 將 word2vec 的結果投影到 2 維的圖:

答: (圖)



2.3. 從上題視覺化的圖中觀察到了什麼?

答:

- 可以大略分成三個區塊, 右上、左下跟中下。
- 右上的那群字幾乎都是每一集的書名裡的字。
- 左下則是幾乎都是人名, first 跟 last name 都出現在這裡。
- 中下則是比較多專有名詞, 像是 Hogwarts, Gryffindor, Slytherin 等。
- 從三大區塊的字詞組成,的確可以看出相似的詞有分在一起。有些比較小的例子也可以看出,像是 aunt 跟 uncle 兩個幾乎重疊,Gryffindor 跟 Slytherin 也是幾乎重疊。
- 3.1. 請詳加解釋你估計原始維度的原理、合理性、這方法的通用性如何?

答:

原理(合理性):

- 在一組 dataset 裡,可以透過找一小部分 data 的分布去預測整體 data 的分布。
- Eigenvalues 可以代表對應的 eigenvectors 在 dataset 中所佔的份量。可以透過取不同數量的 eigenvectors 去當 dataset 的基底向量,也就是用較少維度去描述該 dataset。在這個問題中,可以 想成是有多少夠大的 eigenvalues 就代表應該有多少 eigenvectors 當基底向量,也就代表原始維度 的大小,因此平均 eigenvalues 是跟原始維度相關的。

方法:

- 1. 隨機以助教提供的程式生成原始維度為 1~60 的 data。
- 2. 每個維度生成五組 dataset, 分別是資料數為 10000, 20000, 50000, 80000, 100000 的 dataset。
- 3. 隨機從每個 dataset sample 50 點。
- 4. 找出每一點的 200 個 nearest neighbors, 並把每一組分成一類。
- 5. 算出每一組的 eigenvalues, 並把算出來的值除以每一組最大的 eigenvalue。
- 6. 算出每一組 eigenvalues 的平均。
- 7. 以 SVM 做 supervised 的訓練, 求出給定平均 eigenvalue 能輸出 dimension 的 model。
- 8. 用此 model 預測原始維度 (因為維度都是整數的,所以有對結果做 rounding)。

通用性:

- 因爲一開始產生 data 有用到額外的資訊 (ELU, weight 跟 bias 的大小範圍等),因此這個方法不太 能廣泛的應用。如果要用在其他問題上,一定要在一開始產生 data 那裡做一些更動。
- 3.2. 將你的方法做在 hand rotation sequence datatset 上得到什麼結果?合理嗎?請討論之。答:

因為這兩題的 data 很不一樣,因此我有在一開始產生 data 那裡做一些改變:

- 1. 照片太大 (512×480), 我把它們 resize 成 64×64
- 2. 原本的 intermediate 層的維度從 60~80 改成 100~3000
- 3. 每個維度只產生一組 dataset, 資料數為 481 (hand rotation 照片的數量), neighbors 數改成 20 結果:
- 原始維度=4 (在 4 的上下跳動)。
- 從結果看還算合理,因為這些照片就只是手握著杯子旋轉而已,可以用旋轉角度、手的位置去描述它們。
- 但從理論上來看,這個方法是不合理的,因為我在產生資料的時候,用了很多無關的假設,例如: ELU, weights, biases 等。我覺得用第一題第三小題的方法可能會更具合理性。